AZURE

DATABRICKS • NOVIDADES

Buscar em Chinês, Japonês e Coreano ficou MUITO mais fácil

A dificuldade de pesquisar textos nesses idiomas era um desafio. Agora, isso muda no Databricks.

AZURE

DATABRICKS • NOVIDADES

O desafio dos idiomas sem espaços

Idiomas como Chinês, Japonês e Coreano não usam espaços para separar palavras. Isso confunde buscas tradicionais.

AZURE

DATABRICKS • NOVIDADES

A análise morfológica resolve

A extensão `lakebase_tokenizer` agora usa análise morfológica. Ela segmenta o texto CJK em termos pesquisáveis.

AZURE

DATABRICKS • NOVIDADES

Configurações prontas para usar

```
%sql
SELECT to_tsvector('tokenizer_chinese', '□□□□□
□');
```

Basta usar `tokenizer_chinese`, `tokenizer_japanese` ou `tokenizer_korean` diretamente. Sem criar dicionários.

AZURE

DATABRICKS • NOVIDADES

Buscas inteligentes e precisas

Tratamento de palavras compostas e filtragem inteligente de partículas garantem que você encontre o que realmente importa.

AZURE

DATABRICKS • NOVIDADES

Compatibilidade e performance garantidas

A nova funcionalidade gera valores `tsvector` padrão, compatíveis com índices GIN e BM25 para resultados rápidos e relevantes.

AZURE

DATABRICKS • NOVIDADES

Atualizar é fácil

```
%sql
ALTER EXTENSION lakebase_tokenizer UPDATE;
```

Se você já usa a extensão `lakebase_tokenizer`, basta executar um comando para ter acesso a tudo isso.

AZURE

DATABRICKS • NOVIDADES

O que isso muda para seus dados?

Com essa capacidade de busca aprimorada, como você imagina que a análise de dados em Chinês, Japonês ou Coreano pode evoluir na sua empresa?